#### WSCAD 2017

XVIII Simpósio em Sistemas Computacionais de Alto Desempenho 17-20 de outubro de 2017 – Campinas – São <mark>Paulo - Br</mark>asil

# Introdução à Programação Paralela com OpenMP Além das Diretivas de Compilação

Rogério A. Gonçalves<sup>1</sup>, João M. de Queiroz Filho<sup>1</sup> e Alfredo Goldman<sup>2</sup>

<sup>1</sup>Universidade Tecnológica Federal do Paraná (UTFPR) Departamento de Computação (DACOM) Campo Mourão – PR – Brasil

<sup>2</sup>Universidade de São Paulo (USP)
 Instituto de Matemática e Estatística (IME)
 Centro de Competência em Software Livre (CCSL)
 São Paulo – SP – Brasil

 ${\tt rogerioag@utfpr.edu.br, joaomfilho1995@gmail.com\ e\ gold@ime.usp.br}$ 

XVIII Simpósio em Sistemas Computacionais de Alto Desempenho

### Agenda<sup>l</sup>

- Introdução
- 2 Implementações do OpenMP
- 3 Diretivas de Compilação
- 4 Aplicações
- Considerações Finais
- 6 Referências

#### Material do Minicurso

#### **Material**

Slides e Código dos Exemplos

https://github.com/rogerioag/minicurso-openmp-wscad-2017

#### Objetivos

- Apresentar uma introdução ao OpenMP
- Mostrando o código pós expansão das diretivas de compilação

### Programação Paralela

- Grande parte das linguagens de programação apresentam mecanismos para o uso de threads.
- Criação de threads (spawn) e sincronização do trabalho (join, sync).
- São recursos nativos ou por extensões das linguagens.
- As implementações podem ser de baixo nível ou de mais alto nível.
- A pthread disponível em sistemas GNU/Linux
  - ullet criação de threads:  $pthread\_create(\dots)$
  - sincronização do trabalho: pthread\_join().
- Cilk fornece também funções:
  - para criar threads: cilk\_spawn
  - sincronização: cilk\_sync
  - paralelização de laços: cilk\_for.

#### Padrão OpenMP I

- O OpenMP<sup>1</sup> é um padrão bem conhecido e amplamente utilizado em aplicações para plataformas multicore e manycores.
- A abordagem do OpenMP é de mais alto nível
  - Uso de diretivas de compilação.
  - As diretivas funcionam como anotações no código.
  - Código anotado e não reescrito.
- São implementadas usando-se as diretivas de pré-processamento #pragma, em C/C++, e sentinelas !\$, no Fortran.

#### Padrão OpenMP II

 O OpenMP trabalha em sistemas com memória compartilhada e implementa o modelo fork-join

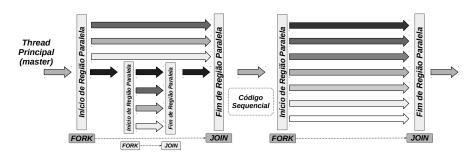


Figura 1: Modelo Fork-join baseado em regiões paralelas

 Múltiplas threads executam tarefas definidas implicitamente ou explicitamente.

### Padrão OpenMP III

- As diretivas são substituídas pelo seu formato de código expandido com as chamadas para o runtime do OpenMP.
- Nosso estudo está baseado nas diretivas de compilação da biblioteca libgomp<sup>2</sup> do GCC.
- A motivação desse estudo foi a necessidade de interceptar código de aplicações OpenMP para decidir sobre offloading de código para aceleradores.

<sup>&</sup>lt;sup>1</sup>Dagum and Menon (1998); OpenMP-ARB (2015); OpenMP Site (2017) <sup>2</sup>GNU Libgomp (2016a,b)

### Implementações do OpenMP I

- O OpenMP tem sido suportado por praticamente todos os compiladores atuais.
- Compiladores como GCC<sup>3</sup>, Intel icc<sup>4</sup> e LLVM clang<sup>5</sup> tem implementações para OpenMP.
- Pelo menos duas implementações: GNU GCC libgomp<sup>6</sup>
   e a Intel libomp (OpenMP\* Runtime Library) <sup>7</sup>.
- A especificação do OpenMP atualmente cobre offloading de código para aceleradores.
- A libgomp é capaz de fazer offloading usando o padrão OpenACC<sup>8</sup>.

```
<sup>3</sup>GCC (2015); GNU Libgomp (2015a)
```

<sup>&</sup>lt;sup>4</sup>Intel (2016b)

<sup>&</sup>lt;sup>5</sup>Lattner and Adve (2004); LLVM Clang (2015); LLVM OpenMP (2015)

<sup>&</sup>lt;sup>6</sup>GNU Libgomp (2015b,c, 2016a,b)

<sup>&</sup>lt;sup>7</sup>Intel (2016a)

<sup>&</sup>lt;sup>8</sup>OpenACC (2015, 2017)

## Diretivas de Compilação e

## Código OpenMP Expandido

(Formato pós expansão das diretivas)

LibGOMP: GNU OpenMP Runtime Library (GNU Offloading and Multi Processing Runtime Library)

## Diretivas de Compilação I

- As diretivas de compilação são formadas por construtores e cláusulas
- Durante a fase de pré-processamento, são substituídos por uma versão de código expandido.
- O formato de código estruturado é composto de chamadas às funções do runtime do OpenMP.
- Verificamos o formato de código gerado para os construtores:
  - Regiões paralelas (parallel region)
  - Laços (for)
  - Tarefas explícitas (task)
  - Tarefas com laços (taskloop)
  - Vetorização (simd)
  - Aceleradores (target)



#### Regiões paralelas: construtor parallel I

- Diretiva: #pragma omp parallel
- Esta é uma das mais importantes diretivas, pois ela é responsável pela demarcação de regiões paralelas.

```
Sintaxe
#pragma omp parallel [clause[ [,] clause] ... ] new-line
{
   /* Bloco estruturado. */
}
```

- Quando uma região paralela é encontrada, é criado um time de threads para executar o código da região.
- Porém, esse construtor não divide o trabalho entre as threads.

#### Regiões paralelas: construtor parallel I

• Quando uma região paralela é declarada:

```
1 #pragma omp parallel
2 {
3   // bloco
4 }
```

- O construtor parallel é implementado criando-se uma nova função com o código do bloco – outlined function.
- Chamadas às funções da libgomp são colocadas no código para delimitar a região paralela:

```
ABI da libgomp

void GOMP_parallel_start(void (*fn)(void *), void *data,
    unsigned num_threads)

void GOMP_parallel_end(void)
```

### Regiões paralelas: construtor parallel II

Cláusulas permitidas com o construtor parallel:

```
Cláusulas

1 if (expression)
2 num_threads (integer - expression)
3 default (shared | none)
4 private (list)
5 firstprivate (list)
6 shared (list)
7 copyin (list)
8 reduction (reduction - identifier : list)
9 proc_bind (master | close | spread)
```

### Regiões paralelas: construtor parallel III

 Após a expansão da diretiva o código gerado assume o formato:

```
1 /* Uma nova função é criada. */
void subfunction (void *data){
 use data:
4 body;
7 /* A diretiva é substituída por chamadas ao runtime
     para criar a região paralela */
8 setup data;
10 GOMP_parallel_start(subfunction, &data, num threads);
11 subfunction(&data);
12 GOMP_parallel_end();
```

#### Regiões paralelas: construtor parallel IV

Obtendo o código intermediário GIMPLE (GCC):

```
Terminal

$ gcc -fopenmp -fdump-tree-all parallel-region.c
$ gcc -fopenmp -fdump-tree-ompexp parallel-region.c
$
```

Gerando a visualização do código GIMPLE:

```
Terminal

$ gcc -fopenmp -fdump-tree-ompexp-graph parallel-region.c
$
```

## Regiões paralelas: construtor parallel V

O código na representação intermediária GIMPLE:

```
1 /* Uma nova função é criada. */
2 main._omp_fn.0 (struct .omp_data_s.0 * .omp_data_i) {
    return:
6 main () {
  int i
  int D.1804;
    struct .omp data s.0 .omp data o.1;
10
11 <bb 2>:
.omp_data_o.1.i = i;
    __builtin_GOMP_parallel_start (main._omp_fn.0, &.omp_data_o
13
        .1, 0);
    main._omp_fn.0 (&.omp_data_o.1);
14
    __builtin_GOMP_parallel_end ();
15
    i = .omp\_data\_o.1.i;
16
17 D.1804 = 0:
18
19 <L0>:
    return D.1804:
20
21 }
```

#### Regiões paralelas: construtor parallel VI

• O código em assembly:

```
Terminal

$ gcc -fopenmp -S parallel-region.c parallel-region.S
$
```

```
1 .file "parallel-region.c"
 2 .text
   .globl main
   .tvpe main. @function
 5
   ; Código da Função main.
   main.
     pushq %rbp
     movq %rsp, %rbp
          $0. %edx
10
     movl
          $0. %esi
11
     movl
12
          $main. omp fn.0, %edi
     movl
          GOMP_parallel_start
13
     call
          $0. %edi
14
     movl
15
     call
          main. omp fn.0
16
     call
          GOMP parallel end
17
     movl
           $0. %eax
```

```
18
     popq %rbp
19 ret
20
   .size main, .-main
21
   : Código da nova função.
   .type main._omp_fn.0, @function
   main. omp fn.0:
25
     pusha %rbp
     movq %rsp, %rbp
26
27
     movg %rdi, -8(\%rbp)
28
     popq %rbp
29
     ret
  .size main. omp fn.0, .-main. omp fn.0
   .ident "GCC: (Debian 4.8.4-1) 4.8.4"
32 .section .note.GNU-stack."".@progbits
```

#### Regiões paralelas: construtor parallel VII

 Exemplo de código com o construtor parallel e algumas cláusulas:

```
1 int main(int argc, char *argv[]) {
    int n = atoi(argv[1]);
    int id. valor = 0:
     printf("Thread[%d][%lu]: Antes da Região Paralela.\n",
         omp_get_thread_num(), (long int) pthread_self());
6
    \#pragma omp parallel if (n>1024) num_threads(4) default(none) shared(
         valor) private(id)
       id = omp_get_thread_num();
       long int id_sys = (long int) pthread_self();
       printf("Thread[%d][%lu]: Código Executado por todas as threads.\n",
10
           id, id sys);
11
12
      #pragma omp master
13
         printf("Thread[%d][%lu]: Código Executado pela thread master.\n",
14
             id, (long int) pthread self());
15
```

## Regiões paralelas: construtor parallel VIII

```
1
       #pragma omp single
 3
         printf("Thread[%d][%lu]: Código Executado por uma das threads.\n",
               id , (long int) pthread_self());
4
5
6
       if (omp_get_thread_num() == 3){
         printf("Thread[%d][%lu]: Código Executado pela thread de id: 3.\n"
              , id (long int) pthread self());
8
9
10
       #pragma omp critical
11
         printf("Thread[%d][%lu]: Executando a região crítica.\n", id, (
12
              long int) pthread_self());
13
         printf("Thread[%d][%lu]: Antes... valor: %d\n", id, (long int)
              pthread_self(), valor);
14
         valor = valor + id:
15
         printf("Thread[%d][% lu]: Depois.. valor: %d\n", id, (long int)
              pthread self(), valor);
16
```

### Regiões paralelas: construtor parallel IX

### Regiões paralelas: construtor parallel X

#### **Terminal**

```
rogerio@chamonix:/src/parallel-with-clauses$ ./example-parallel-with-clauses.exe 4096
```



#### Loops: Construtor for I

- Diretiva: #pragma omp for
- Um time de *threads* é criado quando uma região paralela é alcançada.
- Porém com apenas o construtor de região paralela todas as threads irão executar o mesmo código – outlined function.
- É necessário compartilhar o trabalho e coordenar a execução paralela.
- O construtor for é usado para distribuir o trabalho entre as threads.

#### Construtor for:

```
#pragma omp for schedule ({auto, static, dynamic, guided,
    runtime}, {variable/expression | numerical value/constant})
```

### Loops: Construtor for II

- Semelhante ao que ocorre no processamento do construtor parallel individualmente, um construtor parallel com um construtor for ou o formato combinado parallel for também é implementado com a criação de uma nova função.
- O Código das duas regiões paralelas são equivalentes.

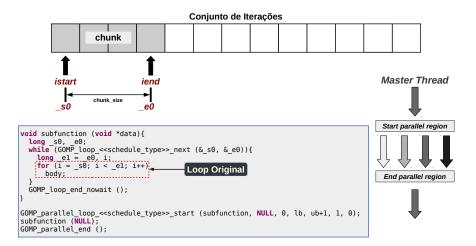
```
1 #pragma omp parallel
2 {
3 #pragma omp for
4 for (i = lb; i <= ub; i++){
5 body;
6 }
7 }</pre>
1 #pragma omp parallel for
2 for (i = lb; i <= ub; i++){
3 body;
4 }
```

### Loops: Construtor for III

- O conjunto de iterações é dividido de acordo com um algoritmo de escalonamento.
- O escalonamento é definido usando-se a cláusula schedule
- O tipos que estão disponíveis no OpenMP são:
  - static
  - $\bullet$  auto
  - runtime
  - dynamic
  - guided
- Quando não se especifica um escalonamento o código é equivalente ao gerado para schedule(static).

### Loops: Construtor for IV

 Como as threads executam os subconjuntos de iterações (chunks) de um laço:



### Loops: Construtor for V

• Exemplo: Quando não é especificado o algoritmo de escalonamento

```
1 int main() {
    int id, i;
3
     printf("Thread[%d][%lu]: Antes da Região Paralela.\n",
        omp_get_thread_num(), (long int) pthread_self());
5
    #pragma omp parallel num_threads(4) default(none) private(id)
6
      // Todas as threads executam esse código.
8
      id = omp_get_thread_num();
10
      #pragma omp for
11
      for (i=0; i<16; i++)
12
         printf("Thread[%d][% lu]: Trabalhando na iteração % lu.\n",
13
              id , (long int) pthread_self(), i);
14
15
     printf("Thread[%d][%lu]: Depois da Região Paralela.\n",
16
        omp_get_thread_num(), (long int) pthread_self());
17
    return 0:
18
19 }
```

#### Loops: Construtor for VI

- O particionamento do conjunto de iterações é estático.
- 16 iterações  $\div 4$  threads

#### Loops: Construtor for VII

• Exemplo: Definindo o escalonamento como schedule(static,2):

```
1 int main() {
    int id, i;
3
     printf("Thread[%d][%lu]: Antes da Região Paralela.\n",
        omp_get_thread_num(), (long int) pthread_self());
5
    #pragma omp parallel num_threads(4) default(none) private(id)
6
      // All threads executes this code.
8
      id = omp_get_thread_num();
10
      #pragma omp for schedule(static,2)
11
      for (i=0; i<16; i++)
12
         printf("Thread[%d][% lu]: Trabalhando na iteração % lu.\n",
13
              id , (long int) pthread_self(), i);
14
15
16
     printf("Thread[%d][% lu]: Depois da Região Paralela.\n",
17
        omp_get_thread_num(), (long int) pthread_self());
18
    return 0;
19
```

#### Loops: Construtor for VIII

- O particionamento do conjunto de iterações é estático.
- 16 iterações  $\div 4$  threads
- Atribuição das iterações segue o chunk\_size em um round-robin nas threads.

#### Loops: Construtor for IX

### Terminal

```
$ gcc -fopenmp -fdump-tree-ompexp for.c
$ gcc -fopenmp -fdump-tree-ompexp-graph for.c
```

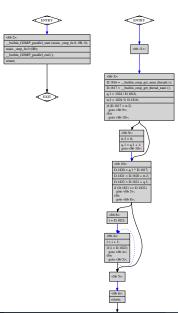
## Loops: Construtor for X

O código em GIMPLE, que é a representação intermediária do GCC:

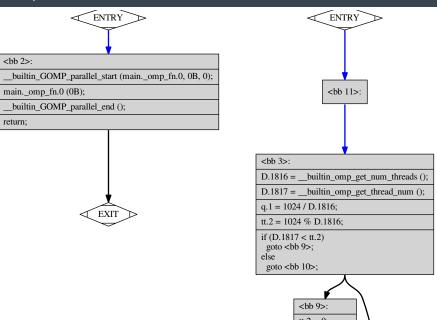
```
main () {
2
  <bb/>bb 2>:
     __builtin_GOMP_parallel_start (main.
          _omp_fn.0, 0B, 0);
     main. omp fn.0 (0B);
     builtin GOMP parallel end ();
     return:
8
9
   main. omp fn.0(void* .omp data i){
11
  <bb >11>:
13
14 <bb 3>:
15
     D.1816 =
           builtin omp get num threads
           ();
     D.1817 =
16
           builtin omp get thread num()
17
     a.1 = 1024 / D.1816:
18
     tt.2 = 1024 % D.1816;
19
     if (D.1817 < tt.2)
20
       goto <bb 9>;
21
     else
22
       goto <bb 10>;
23
24 <bb 10>:
```

```
D.1820 = q.1 * D.1817;
     D.1821 = D.1820 + tt.2;
27
     D.1822 = D.1821 + q.1:
     if (D.1821 >= D.1822)
29
       goto <bb 5>;
30
     else
31
       goto <bb 8>:
32
33
  <bb 8>:
34
     i = D.1821:
35
36 <bb 4>:
37
    i = i + 1:
38
     if (i < D.1822)
39
       goto <bb 4>;
40
     else
41
       goto <bb 5>:
42
43
  <bb 5>:
44
45 <bb 6>:
46
     return:
47
48 <bb 9>:
49
     tt.2 = 0;
50
     q.1 = q.1 + 1;
51
     goto <bb 10>:
52 }
```

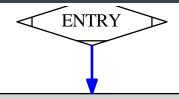
#### Loops: Construtor for



#### Loops: Construtor for



#### Loops: Construtor for



```
<bb >>:
```

\_\_builtin\_GOMP\_parallel\_start (main.\_omp\_fn.0, 0B, 0);

main.\_omp\_fn.0 (0B);

\_\_builtin\_GOMP\_parallel\_end ();

return;

# Loops: Construtor for

```
<br/>bb 3>:
D.1816 = _builtin_omp_get_num_threads();
D.1817 = __builtin_omp_get_thread_num();
q.1 = 1024 / D.1816;
tt.2 = 1024 \% D.1816;
if (D.1817 < tt.2)
 goto <bb/>
y>;
else
 goto <bb 10>;
```



#### Loops: Construtor for I

• **Exemplo:** Laço anotado com o construtor for e com a cláusula schedule(dynamic).

```
1 int main() {
    int id . i i
    printf("Thread[%d][%lu]: Antes da Região Paralela.\n",
        omp_get_thread_num(), (long int) pthread_self());
    #pragma omp parallel num_threads(4) default(none) private(
        id)
      // Todas as threads executam esse código.
       id = omp_get_thread_num();
10
      #pragma omp for schedule(dynamic,2)
11
      for (i=0; i<16; i++)
12
         printf("Thread[%d][%|u]: Trabalhando na iteração %|u.\n
13
              , id , (long int) pthread_self(), i);
14
15
    printf("Thread[%d][%lu]: Depois da Região Paralela.\n",
16
        omp_get_thread_num(), (long int) pthread_self());
    return 0:
17
18 }
```

#### Loops: Construtor for II

 A saída produzida pela execução com escalonamento dynamic:

#### Loops: Construtor for – Formatos I

- Os códigos diferem apenas na definição do limite superior dos laços.
- «schedule\_type»: dynamic, runtime e guided

```
^1 #pragma omp parallel for schedule(<<schedule_type>>) ^2 for ( i = 0; i < 1024; i++){ ^3 // body . ^4 }
```

 Para laços que utilizam escalonamentos dos tipos dynamic, runtime e guided - «schedule\_type»:

 A libgomp usa as funções para delimitar a região paralela de código e criar o primeiro formato do loop:

# ABI libgomp — funções usadas no primeiro formato do parallel for

```
void GOMP_parallel_loop_<<schedule_type>>>_start (void (*fn) (
    void *), void *data, unsigned num_threads, long start, long
    end, long incr);
void GOMP_parallel_end (void);
bool GOMP_loop_<<schedule_type>>>_next(long *istart, long *iend);
void GOMP_loop_end_nowait (void);
```

• O código expandido para o primeiro formato:

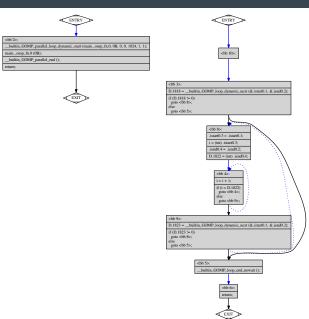
```
void subfunction (void *data){
    long _s0, _e0;
    while (GOMP_loop_<<schedule_type>>_next (&_s0, &_e0)){
      long = e1 = e0, i;
      for (\bar{i} = s\bar{0}; i < e1; i++){
        bodv:
    GOMP loop end nowait ();
10
11
  GOMP parallel loop <<schedule type>> start (subfunction,
       NULL, 0, lb, ub+1, 1, 0);
13 subfunction (NULL);
14 GOMP parallel end ();
```

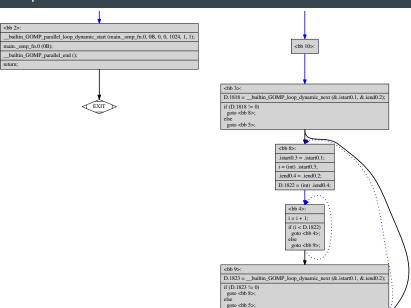
• O código GIMPLE para o primeiro formato:

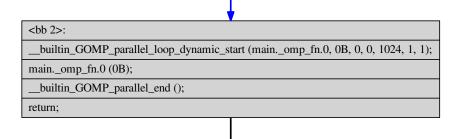
```
1 main () {
  < bb 2 > :
     builtin GOMP parallel loop dynamic start (main. omp fn.0, 0B, 0, 0,
         1024. 1. 1):
     main._omp_fn.0 (0B);
     __builtin_GOMP_parallel_end ();
     return:
8
9
  main._omp_fn.0 (void * .omp_data_i) {
11
  <bb >10>:
13
14 <bb 3>:
     D.1818 = __builtin_GOMP_loop_dynamic_next (&.istart0.1, &.iend0.2);
15
     if (D.1818 != 0)
16
       goto <bb 8>:
17
18
     else
       goto <bb 5>;
19
20
21 <bb 8>:
22
     .istart0.3 = .istart0.1;
     i = (int) . istart0.3;
23
24
     .iend0.4 = .iend0.2
25
     D.1822 = (int) .iend0.4:
```

• O código GIMPLE para o primeiro formato:

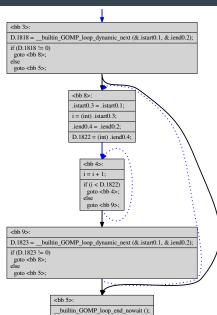
```
1 <bb 4>:
    i = i + 1:
  if (i < D.1822)
    goto <bb 4>:
   else
       goto <bb 9>:
  <bb 9>:
     D.1823 = __builtin_GOMP_loop_dynamic_next (&.istart0.1, &.iend0.2);
     if (D.1823 != 0)
10
       goto <bb 8>:
11
     else
12
13
       goto <bb 5>;
14
15 <bb 5>:
    builtin _GOMP_loop_end_nowait ();
16
17
18 <bb 6>:
     return:
19
20 }
```







**EXIT** 



Para laços que utilizam escalonamentos dos tipos dynamic, runtime
 e guided - «schedule\_type»:

```
  \begin{tabular}{ll} #pragma & omp & parallel & for & schedule(<<schedule_type>>) \\ 2 & n = 1024; \\ 3 & for & (i = 0; i < n; i++) & \{ & body; \\ 5 & \end{tabular}
```

 A libgomp usa as funções para delimitar a região paralela de código e criar o segundo formato do loop:

#### ABI libgomp — funções usadas no segundo formato do parallel for

```
void GOMP_parallel_start (void (*fn) (void *), void *data,
          unsigned num_threads);
void GOMP_parallel_end (void);
void GOMP_parallel_loop_<<schedule_type>>_start (void (*fn) (
          void *), void *data, unsigned num_threads, long start, long
          end, long incr);
bool GOMP_loop_<<schedule_type>>_next(long *istart, long *iend);
void GOMP_loop_end_nowait (void);
```

• O código expandido para o segundo formato:

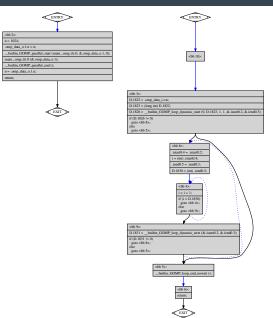
```
void subfunction (void *data){
    long i, _s0, _e0;
    if (GOMP_loop_runtime_start (0, n, 1, &_s0, &_e0)){
      do {
        long _{e1} = _{e0};
        for (i = \_s0; i < \_e0; i++) {
          body:
      while (GOMP_loop_runtime_next (&_s0, &_e0));
10
    GOMP loop end ();
11
12 }
13 /* The annoted loop is replaced. */
14 GOMP_parallel_loop_static (subfunction, NULL, 0, lb,
     ub+1, 1, 0);
15 subfunction (NULL);
16 GOMP_parallel_end ();
```

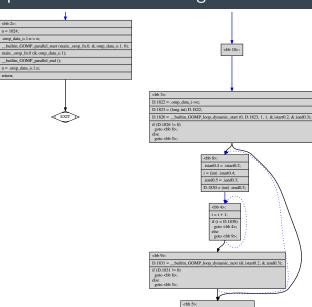
• O código GIMPLE para o segundo formato:

```
1 main () {
     struct .omp data s.0 .omp data o.1;
4 <bb 2>:
    n = 1024:
    .omp data o.1.n = n;
     __builtin_GOMP_parallel_start (main._omp_fn.0, &.omp_data_o.1, 0);
     main._omp_fn.0 (&.omp_data_o.1);
     __builtin_GOMP_parallel_end ();
     n = .omp_data_o.1.n;
10
11
     return;
12 }
13
14
  main._omp_fn.0 (struct .omp_data_s.0 * .omp_data_i) {
15
16 <bb 10>:
17
18 <bb 3>:
     D.1822 = .omp_data_i \rightarrow n;
19
20
     D.1823 = (long int) D.1822;
     D.1826 = builtin GOMP loop dynamic start (0, D.1823, 1, 1, &
21
          .istart0.2 , &.iend0.3);
     if (D.1826 != 0)
22
       goto <bb 8>:
23
24
     else
       goto <bb 5>:
25
```

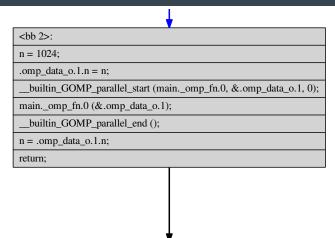
O código GIMPLE para o segundo formato:

```
1 <bb 8>:
     .istart0.4 = .istart0.2;
    i = (int) .istart0.4;
     .iend0.5 = .iend0.3
     D.1830 = (int) .iend0.5;
  <bb 4>:
    i = i + 1:
     if (i < D.1830)
       goto <bb 4>:
10
11
     else
12
       goto <bb 9>;
13
14 <bb 9>:
     D.1831 = \_\_builtin\_GOMP\_loop\_dynamic\_next (\&.istart0.2, \&.iend0.3);
     if (D.1831 != 0)
16
       goto <bb 8>:
17
18 else
19
       goto <bb 5>:
20
21 <bb 5>:
22
     __builtin_GOMP_loop_end_nowait ();
23
24 <bb 6>:
25
     return:
26 }
```





builtin GOMP loop end nowait ():



<bb 3>:

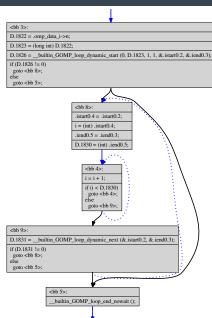
D.1822 = .

D.1823 = 0

D.1826 = ...

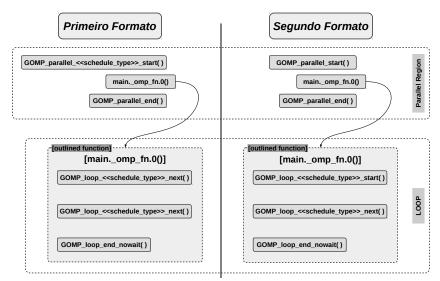
if (D.1826 goto <bb else goto <bb

**EXIT** 



#### Loops: Construtor for - Resumo

Dois formatos de código que são gerados para laços:





# Seções: Construtor sections I

- O sections é um construtor de compartilhamento de trabalho não iterativo
- Define um conjunto de blocos estruturados que são distribuídos entre as *threads* de um time.

```
Sintaxe

1  #pragma omp sections [clause[ [,] clause] ... ] new-line
2  {
3     [#pragma omp section new-line]
4     structured-block
5
6     [#pragma omp section new-line
7     structured-block]
8     ...
9 }
```

#### Seções: Construtor sections II

Cláusulas permitidas para sections:

```
Cláusulas
```

```
private(list)
firstprivate(list)
lastprivate(list)
reduction(reduction-identifier: list)
nowait
```

# Seções: Construtor sections I

- Diretiva: #pragma omp sections
- É utilizada para dividir tarefas entre as *threads* em blocos de código que não possuem iterações.
- Cada *thread* irá executar um bloco de código diferente especificado por #pragma omp section.

#### Sintaxe

```
1 #pragma omp sections
2 {
3     #pragma omp section
4     bloco_1;
5     #pragma omp section
6     bloco_2;
7     #pragma omp section
8     bloco_3;
9 }
```

# Seções: Construtor sections II

Como são implementadas as sections:

```
1 for (i = GOMP\_sections\_start (3); i != 0; i =
     GOMP_sections_next ())
    switch (i) {
      case 1:
        bloco_1;
        break:
    case 2:
        bloco 2;
        break:
   case 3:
        bloco 3:
        break:
11
12
13 GOMP_barrier ();
```

#### • Exemplo utilizando sections com a cláusula reduction:

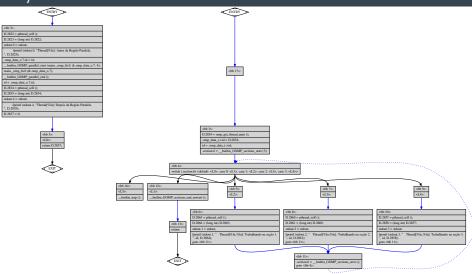
```
int main(int argc, char *argv[]) {
     int i, id;
     int sum = 0:
 4
5
     fprintf(stdout, "Thread[%d][%lu]: Antes da Região Paralela.\n", omp get thread num
           (), (long int)pthread self());
6
7
     #pragma omp parallel num threads(8) private(id)
8
9
       id = omp get thread num():
10
       #pragma omp sections reduction(+:sum)
11
12
         #pragma omp section
13
           fprintf(stdout, " Thread[%|u,%|u]: Trabalhando na secão 1.\n", id, (long
14
                 int) pthread self());
15
           for (i=0; i<1024; i++){
16
             sum += i;
17
18
19
20
         #pragma omp section
21
22
           fprintf(stdout. " Thread[%|u.%|u]: Trabalhando na secão 2.\n". id. (long
                 int) pthread self());
23
           for (i=0; i<1024; i++){
24
             sum += i:
25
26
27
```

# Seções: Construtor sections IV

#### Seções: Construtor sections V

• Saída do exemplo utilizando sections:

# Seções: Construtor sections VI





#### Tarefas: Construtor task |

- Diretiva: #pragma omp task
- O construtor *task* permite a criação de tarefas explícitas.
- Disponível a partir das especificações 3.0 e 3.1
- Implementado pela libgomp do GCC 4.4 e GCC 4.7, respectivamente.

```
Sintaxe

1 #pragma omp task [clause[ [,] clause] ... ] new-line
2 {
3  /* Bloco estruturado. */
4 }
```

 Quando uma thread encontra um construtor task, uma nova tarefa é gerada para executar o bloco associado ao construtor.

#### Tarefas: Construtor task II

- O construtor task é usado dentro de uma região paralela.
- Se for necessário criar apenas uma nova tarefa, o construtor single pode ser utilizado para garantir esse comportamento, caso contrário todas a threads do time irão cria uma nova task.

#### Tarefas: Construtor task III

- Para cada construtor task é criada uma nova função (outlined function) com o código do seu bloco.
- A libgomp utiliza as funções para a criação do formato de código para tasks.

#### ABI da libgomp – Funções usadas a diretiva *task*

#### Tarefas: Construtor task IV

Cláusulas permitidas para o construtor task:

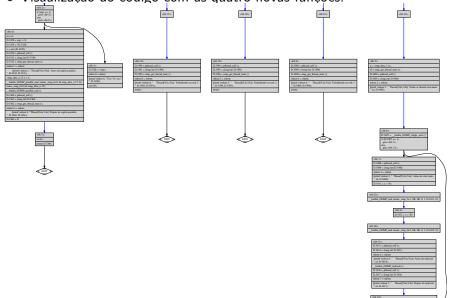
```
Cláusulas
if([task :] scalar-expression)
2 final(scalar-expression)
3 untied
4 default (shared | none)
5 mergeable
6 private(list)
7 firstprivate(list)
8 shared(list)
9 depend (dependence-type: list)
priority(priority -value)
```

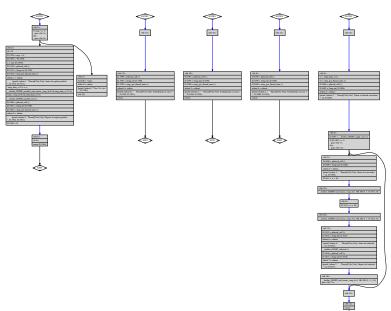
```
int main(int argc, char *argv[]) {
    int id = 0;
2
    int x = atoi(argv[1]);
4
    fprintf(stdout, "Thread[%lu,%lu]: Antes da região paralela.\n
5
        ", omp_get_thread_num(), (long int) pthread_self());
6
7
    #pragma omp parallel num_threads(8) firstprivate(x) private(
        id)
      id = omp_get_thread_num();
      fprintf(stdout, " Thread[%|u,%|u]: Todas as threads
10
          executam.\n", id, (long int) pthread_self());
11
12
      #pragma omp single
13
        fprintf(stdout, " Thread[%|u,%|u]: Antes de criar tasks
14
            .\n", id, (long int) pthread_self());
        #pragma omp task if (x > 10)
15
16
            fprintf(stdout, " Thread[%|u,%|u]: Trabalhando na
17
                task 1.\n", omp_get_thread_num(), (long int)
                pthread_self());
18
```

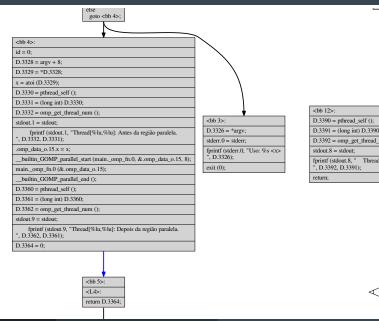
```
#pragma omp task if (x > 20)
1
2
          fprintf(stdout, " Thread[%|u,%|u]: Trabalhando na
3
              task 2.\n", omp_get_thread_num(), (long int)
              pthread_self());
        fprintf(stdout, " Thread[%|u,%|u]: Antes do taskwait.\
            n", id, (long int) pthread_self());
        #pragma omp taskwait
7
        fprintf(stdout, " Thread[%|u,%|u]: Depois do taskwait
8
            .\n", id, (long int) pthread_self());
9
        #pragma omp task
10
11
          fprintf(stdout, " Thread[%|u,%|u]: Trabalhando na
12
              task 3.\n", omp_get_thread_num(), (long int)
              pthread_self());
13
14
15
    fprintf(stdout, "Thread[% lu,% lu]: Depois da região paralela.\
16
        n", omp_get_thread_num(), (long int) pthread_self());
17
```

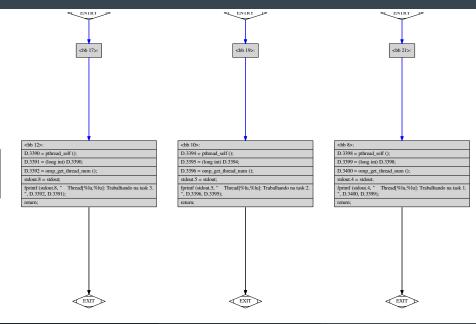
#### Terminal

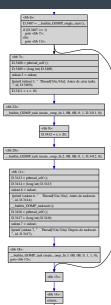
Visualização do código com as quatro novas funções:













### Tarefas com loops: construtor taskloop |

- Diretiva: #pragma omp taskloop
- O construtor taskloop permite distribuir as iterações de um ou mais laços aninhados para tarefas.
- O taskloop é um construtor que especifica que as iterações de um ou mais loops associados serão executadas em paralelo usando OpenMP tasks. As iterações são distribuídas entre as tarefas criadas pelo construtor e escalonadas para serem executadas.

### Tarefas com *loops*: construtor taskloop II

- Quando um construtor taskloop é encontrado uma nova função é criada.
- As tarefas serão criadas e a elas serão associadas um subconjunto de iterações do laço.
- Disponível a partir do GCC 6.x.

#### Construtor taskloop:

```
#pragma omp taskloop [clause[[,] clause] ...] new—line {
// for—loops.
}
```

### Tarefas com *loops*: construtor taskloop III

#### Cláusulas

```
if ([taskloop:]scalar-expression)
2 shared(list)
g private(list)
4 firstprivate(list)
5 lastprivate(list)
6 default (shared | none)
7 grainsize (grain - size)
8 num_tasks(num-tasks)
g collapse(n)
 final(scalar-expr)
  priority ( priority -value )
 untied
 mergeable
14 nogroup
```

### Tarefas com *loops*: construtor taskloop IV

- Para cada construtor task é criada uma nova função (outlined function) com o código do seu bloco.
- A libgomp utiliza as funções para a criação do formato de código para tasks.

#### ABI da libgomp – Funções usadas a diretiva taskloop

### Tarefas com loops: construtor taskloop V

• Exemplo: Distribuindo as iterações do laço com o taskloop.

```
1 int main(int argc, char *argv[])
     fprintf(stdout, "Thread[%lu,%lu]: Antes da Região Paralela.\n", (long int)
          omp_get_thread_num(), (long int) pthread_self());
 3
4
     #pragma omp parallel num threads(4)
5
6
       #pragma omp single
7
         fprintf(stdout, " Thread[%|u.%|u]: Antes das tasks.\n". (long int)
              omp_get_thread_num(), (long int) pthread_self());
9
         #pragma omp taskgroup
10
11
           #pragma omp task
12
13
             fprintf(stdout, "Thread[%|u,%|u]: Trabalhando na task avulsa.\n",
                   omp_get_thread_num(), (long int) pthread_self());
14
15
16
           #pragma omp task
17
18
             fprintf(stdout, "Thread[%|u,%|u]: Trabalhando na task func().\n",
                   omp_get_thread_num(), (long int) pthread_self());
19
             func():
20
21
22
23
24
     fprintf(stdout, "Thread[% lu, % lu]: Depois da Região Paralela.\n", (long int)
          omp_get_thread_num(), (long int) pthread_self());
25
26
     return 0:
```

#### Tarefas com loops: construtor taskloop VI

• Exemplo: Distribuindo as iterações do laço com o taskloop.

### Tarefas com loops: construtor taskloop VII

• O código em GIMPLE, que é a representação intermediária do GCC:

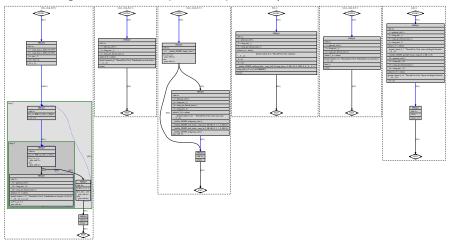


Figura 5:

### Tarefas com *loops*: construtor taskloop VIII

#### Terminal



# Suporte à Vetorização: construtor simd l'

- Diretiva: #pragma omp simd
- O construtor simd pode ser aplicado a um laço diretamente indicando que múltiplas iterações do laço podem ser executadas concorrentemente usando instruções SIMD.
- E pode ser combinado com construtores como o for e taskloop para que o conjunto de iterações seja dividido entre as threads e essas iterações possam ser executadas usando instruções SIMD.

#### Sintaxe

```
\#pragma omp simd [clause[[,] clause] ...]new-line for-loops
```

# Suporte à Vetorização: construtor simd II

• Exemplo: Utilização do construtor simd em um laço que faz a multiplicação de dois *arrays*.

```
1 int main(int argc, char **argv) {
2   int i;
3   double res;
4   init_array();
5
6   #pragma omp simd
7   for (i = 0; i < N; i++) {
8    h_c[i] += h_a[i] * h_b[i];
9   }
10
11   return 0;
12 }</pre>
```

# Suporte à Vetorização: construtor simd III

- O construtor simd n\u00e3o apresenta um formato espec\u00edfico.
- Código do corpo do laço terá instruções SIMD.

```
1 I6.
    movl = -20(\%rbp), %eax
    cltq
    movsd h_c(,\%rax,8), \%mm1
    movl = -20(\%rbp), %eax
     clta
    movsd h_a(,\%rax,8), \%mm2
    movl = -20(\%rbp), %eax
     clta
    movsd h_b(,\%rax,8), \%mm0
10
     mulsd %mm2, %mm0
11
     addsd %mm0. %mm1
12
    movg %mm1, %rax
13
    movl = -20(\%rbp), %edx
14
     movslq %edx, %rdx
15
    movq %rax, h_c(, %rdx, 8)
16
     addl $1, -20(\% rbp)
17
```

# Suporte à Vetorização: construtor simd IV

• **Exemplo:** O construtor simd combinado com o for:

```
1 int main(int argc, char *argv[]) {
    int i:
    /* Inicialização dos vetores. */
    init_array();
5
    #pragma omp parallel for simd schedule (dynamic, 32)
         num_threads(4)
    for (i = 0; i < N; i++) {
      h_c[i] = h_a[i] * h_b[i];
10
    /* Resultados. */
11
    print_array();
12
    check_result();
13
14
15
    return 0;
16 }
```

# Suporte à Vetorização: construtor simd V

- **Exemplo:** O construtor simd combinado com o for.
- O assembly gerado para a função de execução do laço com instruções SIMD em seu corpo.

```
.type main._omp_fn.0, @function
  main. omp fn.0:
   /* Código Suprimido. */
   call GOMP_loop_dynamic_next
   testb %al, %al
    je .L13
  I 17 ·
     /* Código Suprimido. */
  .L15:
     cmpl %edx. -20(\%rbp)
10
11
    jge .L14
12
     movl = -20(\%rbp), %eax
13
     cltq
14
     movsd h_a(,%rax,8), %mm1
15
     movl = -20(\%rbp), %eax
16
     cltq
     movsd h_b(,%rax,8), %mm0
17
     mulsd %mm1. %mm0
18
     movl = -20(\%rbp), %eax
19
20
     clta
21
     movsd %mm0, h_c(,%rax,8)
22
     addl $1, -20(\%rbp)
```

```
imp .L15
24 114
     cmpl $1048576, -20(\%rbp)
    je .L16
27 .L18:
    /* Código Suprimido. */
29
  call GOMP loop dynamic next
    testb %al, %al
31 jne .L17
    imp .L13
33 .L16:
34 /* Código Suprimido. */
35 jmp .L18
36 .L13:
    cmpl $1048576, %ebx
     ie .L19
39 .L20:
     call GOMP loop end nowait
    imp .L21
42 .L19:
43
     /* Código Suprimido. */
```

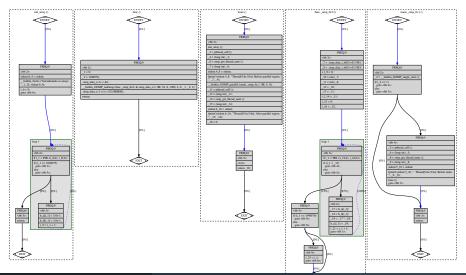
# Suporte à Vetorização: construtor simd VI

- O construtor simd pode também ser combinado com o taskloop.
- O exemplo utiliza os construtores taskloop e simd combinados.
- As iterações do laço serão executadas em paralelo por tasks e as iterações que cada thread executa podem ser transformadas em instruções SIMD.

```
1 void func(){
2   int i;
3
4   #pragma omp taskloop simd num_tasks(4)
5   for (i = 0; i < N; i++) {
6     h_c[i] = h_a[i] * h_b[i];
7   }
8 }</pre>
```

# Suporte à Vetorização: construtor simd VII

 Toda a estrutura de execução do construtor taskloop e dos construtores utilizados na região paralela é criada.





# Offloading para Aceleradores: construtor target I

- Para falarmos sobre diretivas de compilação para aceleradores temos que introduzir o modelo de programação para aceleradores como as GPUs.
- Para esse tipo de dispositivo acelerador é necessário definir uma função kernel que terá sua execução lançada no dispositivo.

```
1 __global__ void vecAdd(float *a, float *b, float *c, int n)
2 {
3   int id = blockIdx.x * blockDim.x + threadIdx.x;
4   if (id < n)
5    c[id] = a[id] + b[id];
6 }</pre>
```

# Offloading para Aceleradores: construtor target II

• Declaração dos dados e ponteiros no dispositivo:

```
1 int main( int argc, char* argv[] ){
    float *h a;
    float *h b;
    float *h_c;
    // Declaração dos vetores de entrada na memória da GPU.
    float *d a:
    float *d b;
       Declaração do vetor de saída do dispositivo.
10
    float *d c;
11
    // Tamanho em bytes de cada vetor.
12
    size_t bytes = n * sizeof(float);
13
14
    // Alocação de memória para os vetores do host.
15
    h_a = (float*) malloc(bytes);
16
    h_b = (float*) malloc(bytes):
17
    h c = (float*) malloc(bytes);
18
19
    // Alocação de memória para cada vetor na GPU.
20
    cudaMalloc(&d_a, bytes);
21
    cudaMalloc(&d_b, bytes);
22
    cudaMalloc(&d c, bytes);
23
```

# Offloading para Aceleradores: construtor target III

 CUDA fornece função para realizar transferências de dados entre a memória principal e a memória do dispositivo.

```
// Cópia dos vetores do host para o dispositivo.
cudaMemcpy( d_a, h_a, bytes, cudaMemcpyHostToDevice
);
cudaMemcpy( d_b, h_b, bytes, cudaMemcpyHostToDevice
);
```

# Offloading para Aceleradores: construtor target IV

- Então é feita a chamada à função kernel.
- Na ativação do kernel a configuração da estrutura do arranjo de threads (grid e bloco) precisa ser definida explicitamente pelo programador.
- Essa configuração determina quantas threads serão criadas e como estarão organizadas em blocos dentro do grid mapeado para o dispositivo.

```
int blockSize, gridSize;

// Número de threads em cada bloco de threads.
blockSize = 1024;

// Número de blocos de threads no grid.
gridSize = (int)ceil((float)n/blockSize);

// Chamada a função kernel.
vecAdd<<<<gri>gridSize, blockSize>>>(d_a, d_b, d_c, n);
```

# Offloading para Aceleradores: construtor target V

- Cópia do resultado (d\_c) da soma de vetores realizada no dispositivo para (h\_c) na memória do host.
- Liberação da memória alocada.

```
// Cópia do vetor resultado da GPU para o host.
    cudaMemcpy(h c, d c, bytes, cudaMemcpyDeviceToHost
    // Liberação da memória da GPU.
    cudaFree(d_a);
    cudaFree(d b);
    cudaFree(d c);
    // Liberação da Memória do host.
    free(h_a);
10
    free(h b):
11
    free(h c):
12
13
    return 0;
14
15 }
```

# Offloading para Aceleradores: construtor target VI

- No contexto de diretivas de compilação o padrão OpenACC fornece um conjunto de diretivas.
- Laços paralelizáveis anotados para serem transformados em *kernel* para um dispositivo.
- Cada diretiva em C/C++ inicia com #pragma acc e existem construtores e cláusulas para a criação de kernels com base em laços.

```
#pragma acc directive -name [clause [[,] clause]...]
new-line
```

# Offloading para Aceleradores: construtor target VII

 O exemplo soma de vetores escrito com as diretivas do OpenACC.

```
1 void vecaddgpu(float *restrict c, float *a, float *b, int n){
    #pragma acc kernels for present(c,a,b)
    for ( int i = 0; i < n; ++i )
      c[i] = a[i] + b[i];
  int main( int argc, char* argv[] ){
8
    #pragma acc data copyin(a[0:n],b[0:n]) copyout(c[0:n])
10
      vecaddgpu(c, a, b, n);
11
12
13
14
    return 0:
15 }
```

Código 4: Exemplo de Soma de Vetores anotado com diretivas OpenACC

### Offloading para Aceleradores: construtor target VIII

A saída gerada pelo compilador pgcc:

# Offloading para Aceleradores: construtor target IX

- Para offloading de código para dispositivos aceleradores, no OpenMP temos o construtor target.
- Diretiva: #pragma omp target

```
#pragma omp target [clause[ [ , ] clause] ... ] new-line
bloco-estruturado
```

# Offloading para Aceleradores: construtor target X

- O Código apresenta os construtores target e parallel for combinados.
- O construtor target faz o mapeamento de variáveis para a memória do dispositivo e lança a execução do código no dispositivo.
- Uma função com o código associado ao construtor target é criada para ser executada no dispositivo alvo.
- O dispositivo alvo (device target) pode ser definido chamando a função omp\_set\_default\_device(int device\_num) com o número do dispositivo sendo passado como argumento ou definindo-se a variável de ambiente OMP\_DEFAULT\_DEVICE ou ainda usando a cláusula device(device\_num).

## Offloading para Aceleradores: construtor target XI

• Exemplo: Soma de vetores.

```
void vecaddgpu(float *c, float *a, float *b, int n){

#pragma omp target device(0)

#pragma omp parallel for private(i)

for( int i = 0; i < n; ++i ){

    c[i] = a[i] + b[i];

}

</pre>
```

## Offloading para Aceleradores: construtor target XII

 O mapeamento de dados para o dispositivo pode ser feito usando-se a cláusula map admitida pelo construtor target.

```
void vecaddgpu(float *c, float *a, float *b, int n){
    #pragma omp target map(to: a[0:n], b[:n]) map(from: c[0:n])
    #pragma omp parallel for private(i)

for( int i = 0; i < n; ++i ) {
    c[i] = a[i] + b[i];
}
</pre>
```

## Offloading para Aceleradores: construtor target XIII

- O construtor target também permite a escolha de fazer o offloading do código para o dispositivo ou não, utilizando a cláusula if.
- As transferências de dados também podem ser declaradas com o construtor target data que cria um novo ambiente de dados que será utilizado pelo kernel.

```
1 #define THRESHOLD 1024
2
3 void vecaddgpu(float *c, float *a, float *b, int n){
4  #pragma omp target data map(to: a[0:n], b[:n]) map(from: c[0: n]) if (n>THRESHOLD)
5  {
6     #pragma omp target if (n>THRESHOLD)
7     #pragma omp parallel for if (n>THRESHOLD)
8     for( int i = 0; i < n; ++i )
9         c[i] = a[i] + b[i];
10  }
11 }</pre>
```

# Offloading para Aceleradores: construtor target XIV

 Especificar uma região de dados pode ser útil para múltiplos kernels

```
1 #define THRESHOLD 1048576
2
  void vecaddgpu(float *c, float *a, float *b, int n){
    #pragma omp target data map(from: c[0:n])
      #pragma omp target if(n>THRESHOLD) map(to: a[0:n], b[:n])
6
      #pragma omp parallel for
       for (int i = 0; i < n; ++i)
        c[i] = a[i] + b[i];
10
      // Reinicialização dos dados.
11
       init(a,b);
12
13
      #pragma omp target if(n>THRESHOLD) map(to: a[0:n], b[:n])
14
      #pragma omp parallel for
15
       for ( int i = 0; i < n; ++i )
16
        c[i] = c[i] + (a[i] * b[i]);
17
18
19
20 }
```

## Offloading para Aceleradores: construtor target XV

 Atualização dos dados entre as execuções dos kernels é utilizando o construtor target update.

```
1 void vecaddgpu(float *c, float *a, float *b, int n){
    int changed = 0;
    #pragma omp target data map(to: a[0:n], b[:n]) map(from: c[0:
        n])
      #pragma omp target
      #pragma omp parallel for
       for (int i = 0; i < n; ++i)
7
        c[i] = a[i] + b[i];
      changed = init(a,b);
10
11
      #pragma omp target update if(changed) to(a[0:n], b[:n])
12
13
14
      #pragma omp target
      #pragma omp parallel for
15
       for ( int i = 0; i < n; ++i )
16
        c[i] = c[i] + (a[i] * b[i]);
17
18
19 }
```

## Offloading para Aceleradores: construtor target XVI

 O exemplo de soma de vetores feito OpenMP utilizando o construtor target e suas combinações vistas nos exemplos anteriores.

```
1 #define THRESHOLD 1024
 float *h a;
 float *h_b;
  float *h_c;
 int n = 0:
  /* Código Suprimido. */
  void vecaddgpu(float *c, float *a, float *b){
    #pragma omp target data map(to: a[0:n], b[:n]) map(from: c[0:
10
        n]) if (n>THRESHOLD)
11
12
      #pragma omp target if(n>THRESHOLD)
      #pragma omp parallel for if (n>THRESHOLD)
13
      for ( int i = 0; i < n; ++i ){
14
        c[i] = a[i] + b[i]:
15
16
17
18 }
```

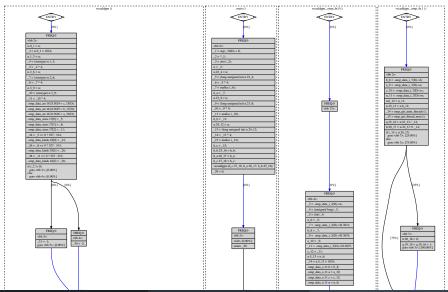
# Offloading para Aceleradores: construtor target XVII

 O exemplo de soma de vetores feito OpenMP utilizando o construtor target e suas combinações vistas nos exemplos anteriores.

```
1 int main(int argc, char *argv[]) {
    int i:
    n = atoi(argv[1]);
    h_a = (float*) malloc(n*sizeof(float));
    h_b = (float*) malloc(n*sizeof(float));
    h_c = (float*) malloc(n*sizeof(float));
    init_array();
10
    vecaddgpu(h_c, h_a, h_b);
11
12
13
    return 0:
14 }
```

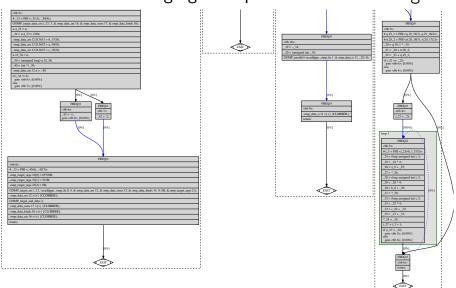
## Offloading para Aceleradores: construtor target XVIII

• Estrutura do Código gerado para o construtor target:



## Offloading para Aceleradores: construtor target XIX

• Estrutura do Código gerado para o construtor target:



## Offloading para Aceleradores: construtor target XX

 As funções relacionadas com a geração de código para o construtor target que identificamos na ABI da libgomp:

#### ABI libgomp – Funções relacionadas com o construtor *target*

```
void GOMP_parallel (void (*fn) (void *), void *data, unsigned
    num_threads, unsigned int flags)
void GOMP_target_data_ext (int device, size_t mapnum, void **
    hostaddrs, size_t *sizes, unsigned short *kinds)
void GOMP_target_end_data (void)
void GOMP_target_update (int device, const void *unused, size_t
    mapnum, void **hostaddrs, size_t *sizes, unsigned char *kinds
    )
void GOMP_target_ext (int device, void (*fn) (void *), size_t
    mapnum, void **hostaddrs, size_t *sizes, unsigned short *
    kinds, unsigned int flags, void **depend, void **args)
```

## Offloading para Aceleradores: construtor target XXI

 Como o código utiliza a cláusula if para decidir se deve ou não fazer o offloading com base no tamanho dos dados.

```
rogerio@ragserver:~/example-target$ nvprof ./example-target.exe 16384
                                                          [CUDA memcpv DtoH]
```

# Offloading para Aceleradores: construtor target XXII

• Da mesma forma o exemplo foi executado com n=512 e podemos verificar com o nvprof que o offloading de código não foi feito.

```
Terminal
rogerio@ragserver:-/example-target$ nvprof ./example-target.exe 512
Inicializando os arrays.
Verificando o resultado.
Resultado Final: (512.000000, 1.000000)
=========== Warning: No CUDA application was profiled, exiting
```

 Nenhuma operação relacionada ao dispositivo (transferências de dados e lançamento da execução de kernels) que caracterizaria o offloading de código aconteceu.



## Aplicações I

- Conhecer como é o formato de código gerado e as funções da ABI do runtime do OpenMP pode ser útil para a construção de bibliotecas de interceptação de código via hooking.
- O que pode cobrir desde logging, criação de traces<sup>a</sup>, monitoramento<sup>b</sup> e avaliação de desempenho ou offloading de código para dispositivos aceleradores.
- Para criar hooks para funções da libgomp é necessário criar uma biblioteca que tenha funções com o mesmo nome das funções disponibilizadas em sua ABI.
- Uma vez que a biblioteca de hooking seja carregada antes da biblioteca libgomp, os símbolos como as chamadas para as funções do runtime do OpenMP serão ligados aos símbolos da biblioteca de interceptação.

<sup>&</sup>lt;sup>a</sup>Trahay et al. (2011)

<sup>&</sup>lt;sup>b</sup>Mohr et al. (2002)

#### Aplicações II

## Aplicações III

• Uma macro pode ser definida para recuperar os ponteiros para as funções originais do runtime OpenMP:

```
#define GET_RUNTIME_FUNCTION(hook_func_pointer,func_name) \
    do {
      if (hook func pointer) break;
      void * handle = RTLD NEXT;
      hook_func_pointer = (typeof(hook_func_pointer)) (uintptr_t)
           dlsym(__handle, func_name);
     PRINT_ERROR();
   } while(0)
9 #if defined(VERBOSE) && VERBOSE > 0
    #define PRINT_FUNC_NAME fprintf(stderr, "TRACE-FUNC-NAME:
10
        [%10s:%07d] Thread [%lu] is calling [%s()]n",__FILE__,
        __LINE___, (long int) pthread_self(), __FUNCTION___)
11 #else
    #define PRINT FUNC NAME (void) 0
13 #endif
```

## Aplicações IV

- Função proxy para a função original utilizando a macro.
- Chamadas de funções para executar algum código antes (PRE\_) ou algum código depois (POST\_).

```
1 void GOMP_parallel_start (void (*fn) (void *), void *data,
      unsigned num_threads){
    PRINT_FUNC_NAME;
    /* Retrieve the OpenMP runtime function. */
    GET_RUNTIME_FUNCTION(lib_GOMP_parallel_start,
        GOMP parallel start"):
6
    PRE_GOMP_parallel_start();
10
    lib_GOMP_parallel_start(fn, data, num_threads);
11
12
13
    POST_GOMP_parallel_start();
14
15 }
```

## Aplicações V

 Função proxy para a função de inicialização de laço com escalonamento do tipo dynamic.

```
1 void GOMP_parallel_loop_dynamic_start (void (*fn) (void *),
      void *data.
2 unsigned num_threads, long start, long end,
 long incr, long chunk size){
    PRINT_FUNC_NAME;
5
    /* Retrieve the OpenMP runtime function. */
    GET_RUNTIME_FUNCTION(lib_GOMP_parallel_loop_dynamic_start, "
7
        GOMP parallel loop dynamic start");
10
    PRE_GOMP_parallel_loop_dynamic_start();
11
12
    lib_GOMP_parallel_loop_dynamic_start(fn, data, num_threads,
13
        start, end, incr, chunk_size);
14
    /* Código a ser executado depois. */
15
    POST_GOMP_parallel_loop_dynamic_start();
16
```

## Aplicações VI

A função proxy para a função de término de laços de repetição.

```
1 void GOMP loop end (void){
    PRINT_FUNC_NAME;
3
    /* Retrieve the OpenMP runtime function. */
    GET_RUNTIME_FUNCTION(lib_GOMP_loop_end, "GOMP_loop_end");
6
    /* Código a ser executado antes. */
    PRE_GOMP_loop_end();
8
9
    /* Chamada à função original. */
10
    lib_GOMP_loop_end();
11
12
13
    POST GOMP loop end():
14
15 }
```

## Aplicações VII

• Função *proxy* capaz de interceptar a função de criação de *tasks*.

```
1 void GOMP_task (void (*fn) (void *), void *data, void (*cpyfn)
      (void *, void *),
2 long arg_size, long arg_align, bool if_clause, unsigned flags,
3 void **depend){
    PRINT_FUNC_NAME;
    /* Retrieve the OpenMP runtime function. */
    GET_RUNTIME_FUNCTION(lib_GOMP_task, "GOMP_task");
7
8
    /* Código a ser executado antes. */
9
    PRE GOMP task():
10
11
    /* Chamada à função original. */
12
    lib_GOMP_task(fn, data, cpyfn, arg_size, arg_align, if_clause
13
        , flags , depend);
14
15
    /* Código a ser executado depois. */
    POST_GOMP_task();
16
17 }
```

## Aplicações VIII

 Parte da saída da execução do exemplo do uso do construtor task com a biblioteca de interceptação:

```
rogerio@chamonix:/src/simple-omp-hook/tests/parallel-region-with-
   PRE_GOMP_parallel_start()]
   POST_GOMP_parallel_start()]
```

## Considerações Finais

- Pelo fato do OpenMP ser um padrão amplamente utilizado em aplicações paralelas para sistemas multicore e com aceleradores, é importante conhecer sobre o seu funcionamento.
- Pois em alguns casos não é simplesmente anotar o código, é necessário saber se o mesmo é paralelizável, um laço de repetição é um bom exemplo disso.
- Mas ainda assim o uso de diretivas de compilação tem uma grande vantagem com relação ao uso de bibliotecas para criação de aplicações multithreading como a pthreads.
- A quantidade de código a ser escrito inserindo anotações nos devidos lugares é muito menor.
- Existem diversas outras diretivas de compilação do OpenMP e implementações que não foram abordadas neste curso.

#### Referências I

- Dagum, L. and Menon, R. (1998). OpenMP: An Industry-Standard API for Shared-Memory Programming. *IEEE Computational Science and Engineering*, 5(1):46–55.
- GCC (2015). GCC, the GNU Compiler Collection.
- GNU Libgomp (2015a). GNU libgomp, GNU Offloading and Multi Processing Runtime Library documentation (Online manual).
- GNU Libgomp (2015b). GNU Offloading and Multi Processing Runtime Library: The GNU OpenMP and OpenACC Implementation. Technical report, GNU.
- GNU Libgomp (2015c). GNU Offloading and Multi Processing Runtime Library: The GNU OpenMP and OpenACC Implementation. Technical report, GNU libgomp.
- GNU Libgomp (2016a). GNU Offloading and Multi Processing Runtime Library: The GNU OpenMP and OpenACC Implementation. Technical report, GNU libgomp.
- GNU Libgomp (2016b). GNU Offloading and Multi Processing Runtime Library: The GNU OpenMP and OpenACC Implementation. Technical report, GNU libgomp.
- Intel (2016a). Intel® OpenMP\* Runtime Library Interface. Technical report, Intel. OpenMP\* 4.5, https://www.openmprtl.org.
- Intel (2016b). OpenMP\* Support. https://software.intel.com/pt-br/node/522678.

#### Referências II

- Lattner, C. and Adve, V. (2004). LLVM: A Compilation Framework for Lifelong Program Analysis & Transformation. In *Proceedings of the International Symposium on Code* Generation and Optimization, number c in CGO '04, pages 75–86, Palo Alto, California. IEEE Computer Society.
- LLVM Clang (2015). clang: a C language family frontend for llvm.
- LLVM OpenMP (2015). OpenMP®: Support for the OpenMP language.
- Mohr, B., Malony, A. D., Shende, S., and Wolf, F. (2002). Design and Prototype of a Performance Tool Interface for OpenMP. *The Journal of Supercomputing*, 23(1):105–128.
- OpenACC (2015). OpenACC Application Programming Interface. Version 2.5. http://www.openacc.org/sites/default/files/OpenACC\_2pt5.pdf.
- $Open ACC\ (2017).\ Open ACC\ -\ More\ Science,\ Less\ Programming.\ http://www.openacc.org/.$
- OpenMP-ARB (2015). OpenMP Application Program Interface Version 4.5. Technical report, OpenMP Architecture Review Board (ARB). Version 4.5.
- OpenMP Site (2017). OpenMP  $^{\otimes}$  Enabling HPC since 1997: The OpenMP API specification for parallel programming.
- Trahay, F., Rue, F., Faverge, M., Ishikawa, Y., Namyst, R., and Dongarra, J. (2011). EZTrace: a generic framework for performance analysis. In *IEEE/ACM International Symposium on Cluster, Cloud and Grid Computing (CCGrid)*, Newport Beach, CA, United States. Poster Session.

#### Fim



#### Contato

Rogério Aparecido Gonçalves:

rogerioag@utfpr.edu.br

• João M. de Queiroz Filho: joaomfilho1995@gmail.com

• Alfredo Goldman:

gold@ime.usp.br

#### Informações

O material desse minicurso foi preparado no âmbito dos projetos "Escola de Computação Paralela" (UTFPR DIREC  $\mathbb{N}^2$  028/2017) e "Estudo Exploratório sobre Técnicas e Mecanismos para Paralelização Automática e Offloading de Código em Sistemas Heterogêneos" (UTFPR PDTI  $\mathbb{N}^2$  916/2017).

#### Material disponível em:

https://github.com/rogerioag/minicurso-openmp-wscad-2017